

김민영.

ML / MLOps Engineer

premierckim@gmail.com · github.com/my0614 · Seoul

기술 스택

Language	Python · C
NLP/LLM	LLM · RAG · Azure OpenAI · Prompt Engineering
Vision	YOLOv5 · Faster R-CNN · RetinaNet · MMDetection · MambaCD
AI Framework	PyTorch · LangChain
Backend	Flask · FastAPI
DB	PostgreSQL · Redis · ChromaDB(Vector DB)
Infra	Docker · Kubernetes
Cloud	Azure · AWS EC2
Else	Git · Jira · Label Studio · MLflow

경력

(주)무무즈

매니저 · P&C · 2025.12 ~ 2026.03 (4개월)

이커머스 운영 자동화 시스템 구축을 통한 운영 효율 개선

핫딜 자동화 시스템 · 2025.12 ~ 2026.03

핫딜 등록 E2E 자동화 파이프라인

원인 파트너사 핫딜 신청부터 상품 선정·등록·결과 메일 발송까지 전 과정이 수작업으로 진행되어 등록 작업에만 4시간 이상 소요

해결 End-to-End 자동화 파이프라인 설계, Shopby API 연동 및 동적 스코어링으로 상위 200개 자동 선별

결과 작업 시간 4시간에서 2분으로 단축(99% 감소), 전 과정 무인 자동화

OAuth 2.0 통합 인증 및 무중단 배치

원인 Gmail·Sheets·Drive 3개 API를 개별 인증하던 구조에서 새벽 배치 실행 중 인증 만료로 파이프라인이 끊길 위험

해결 OAuth 2.0 단일 credential 통합 인증 및 Refresh Token 자동 재발급 구조 설계

결과 무중단 배치 파이프라인 확보

Bitbucket Pipelines CI/CD

원인 Bitbucket Pipelines 미도입 상태로 배포 시마다 수동 반영

해결 push, 테스트, EC2 배포까지 CI/CD 자동화 구축, dev/prod 브랜치별 배포 환경 분리

결과 배포 리드타임 단축, 배포 실수 리스크 제거

CS 문의 자동화 · 2025.12 ~ 2026.03

이중 API 기반 자동 응답 파이프라인

원인 반복되는 배송 문의를 상담원이 수동 처리, 주말·비업무 시간 대응 불가로 응답 지연 발생

해결 Shopby·Sellmate 이중 API 매칭 기반 케이스 자동 분기 로직 구현, cron 배치로 24/7 무중단 처리

결과 문의의 1/3 자동 처리, 응답 지연 시간 80% 단축

케이스 분기 로직 설계

원인 문의 유형이 뒤섞여 있어 자동 응답 오발송 리스크 존재

해결 상품코드·송장번호 유무 조합으로 3케이스 분기, 처리 불가 케이스는 담당자 플래그로 분리

결과 오발송 리스크 제거, 응답 품질 일관성 확보

한컴인스페이스

연구원 · 소프트웨어플랫폼사업팀 · 2021.10 ~ 2025.12 (4년 3개월)

AI 모델 학습·추론 파이프라인 고도화 및 위성·드론 영상 서비스 운영 효율 개선

사내 MLOps 플랫폼 DFLOW · 2022.01 ~ 2024.12

통합 ML 백엔드 인터페이스

원인 모델별로 입력 포맷·학습 방식·출력 구조가 달라 신규 모델 추가마다 반복 재구현 필요

해결 GOD·MMDetection·MMYOLO 3개 프레임워크를 단일 ML 백엔드 인터페이스로 추상화

결과 지원 모델 3개에서 20개 이상으로 확장, 신규 온보딩 1~2주에서 1일로 단축

Redis BRPOP 기반 학습 작업 큐

원인 DB 폴링 방식의 학습 작업 큐에서 race condition으로 다중 Pod 환경 순서 보장 불가

해결 Redis BRPOP 원자적 큐와 Redis Hash 상태 관리로 전환

결과 학습 대기 하루 이상 걸리던 것을 자동 순차 처리로 해소

nvidia-smi 기반 GPU 동적 분배

원인 GPU 가용 메모리 확인 없이 학습을 배정해 멀티 GPU 환경에서 OOM 장애 반복

해결 nvidia-smi로 가용 메모리를 체크한 뒤 모델 요구량과 비교해 동적으로 GPU 분배

결과 멀티 GPU OOM 장애 제거

드론 탑재 실시간 객체 탐지 · 3D 가시화 · 2023.01 ~ 2025.12

RGB/Depth 프레임 동기화

원인 RGB/Depth ROS Topic 프레임 불일치로 실시간 거리 계산 정확도 저하

해결 ApproximateTimeSynchronizer로 slop-queue size를 실측 튜닝해 프레임 동기화

결과 거리 오차 30~40% 감소

실환경 데이터 확장 및 재학습

원인 저조도·빛번짐 환경에서 오토탐·미탐이 빈번해 mAP 61%에 그침

해결 원인별 데이터를 2,000장에서 6,000~7,000장으로 확장해 재학습

결과 mAP 61%에서 75%로 향상(14%p), KTL 시험 성적서 발급

네트워크 환경 자동 세팅

원인 드론·환경마다 네트워크 설정이 달라 수동 세팅에 2시간 이상 소요

해결 서브넷 기반 환경 자동 판별과 IP 자동 세팅 로직 구현

결과 네트워크 세팅 시간 2시간에서 1분 이하로 단축(99% 감소)

EO/IR UAV 실시간 탐지·추적 시스템 · 2024.06 ~ 2024.12

EO/IR 도메인별 모델 분리 학습

원인 EO·IR 이미지를 단일 데이터셋으로 학습해 IR 환경에서 새·항공기 오토탐 빈번

해결 EO/IR 도메인별로 데이터셋을 분리해 독립 학습

결과 주야간 모두 안정적인 탐지 성능 확보

소형 객체 특화 모델 최적화

원인 표준 앵커·입력 해상도로는 원거리 소형 UAV 탐지율 저하

해결 고해상도 입력과 소형 객체 특화 앵커·증강 적용

결과 소형 객체 탐지율 향상, 미탐 감소

K8s 6파드 RTSP 병렬 처리

원인 단일 파드로 다중 카메라 스트림 처리 시 한 채널 장애가 전체에 영향

해결 K8s 6개 파드로 EO/IR 카메라별 RTSP 스트림을 독립 처리

결과 **6채널 실시간 병렬 처리, 장애 격리**

사이드 프로젝트

뽀라인드 — 부부·연인 관계 케어 AI 웹앱

Team Project · 5인 팀 DB/AI 분석 파이프라인 담당 · 2026.06 ~ 07

LangChain 기반 RAG 상담 챗봇

원인 가사소송법·판례 상담 답변에 근거가 없어 신뢰도가 낮음

해결 LangChain과 Azure AI Search로 법령·판례를 벡터 검색한 뒤 근거를 명시하는 RAG 파이프라인 설계

결과 **출처를 명시한 상담 응답 생성**

pgvector 기반 유사도 검색

원인 키워드 매칭만으로는 표현이 달라도 맥락이 유사한 고민을 찾지 못함

해결 PostgreSQL pgvector로 임베딩 유사도 기반 추천·중복 판별 구현

결과 **별도 벡터 DB 인프라 없이 추천과 중복판별 동시 처리**

LLM 감정 분석 구조화

원인 감정·원인·패턴을 자유 문장으로 추출하면 DB 집계·리포트 신뢰성이 떨어짐

해결 14개 그룹, 81개 라벨 JSON Schema 강제 포맷으로 구조화 추출

결과 **필드 누락·포맷 깨짐 없이 안정적으로 DB에 저장**

PillCare — AI 기반 건강 위험 분석 서비스

식약약 공공데이터·AI 분석·활용 경진대회 · 2026.05

FastMCP 건강 데이터 서버

원인 건강 데이터 분석 로직이 API마다 흩어져 있어 AI 어시스턴트가 실시간으로 활용하기 어려움

해결 FastMCP 서버로 건강 지수·약물 안전도·환경 지수 3개 Tool 구현

결과 **AI Agent가 실시간 사용자 데이터를 직접 조회해 개인화 응답 생성**

OpenAI Vision OCR 자동 등록

원인 처방봉투 정보를 수기로 입력해야 하는 번거로움

해결 OpenAI Vision API로 약품명·용량·복용 시점 자동 추출

결과 **복약 스케줄 자동 등록, 수동 입력 단계 제거**

3단계 멀티 레이어 캐시

원인 동일 질의가 반복될 때마다 OpenAI 호출 비용이 그대로 발생

해결 L1 인메모리, L2 Redis, L3 OpenAI 3단계 캐시 설계

결과 **비용 절감, Redis 장애 시에도 무중단 풀백 확보**

이약머약 — AI 알약 식별 서비스

MS AI School 10기 · Team 4 U · 2026.05.08 ~ 05.20

핵심 90종 분류 모델 구축

원인 전 성분·전 제형을 무분별하게 수집하면 클라우드 비용 부담과 데이터 오염 위험 증가

해결 처방 통계·판매량 기반으로 핵심 90종을 선별, 학습 데이터 3,773개로 분류 모델 구축

결과 **성능지표 평균 97% 달성**

FastAPI 비동기 예측 연동

원인 동기 처리로는 다수 요청 시 응답 지연 우려

해결 Azure Python SDK 예측 API를 FastAPI 비동기 엔드포인트와 통합

결과 **AI 분석 평균 응답 2.4초**

Azure VM 올인원 배포

원인 2주라는 짧은 개발 기간 내 기획부터 배포까지 완결해야 하는 제약
해결 Azure VM 단일 서버에 FastAPI, PostgreSQL, Nginx를 올인원 배포
결과 2주 내 기획, 학습, 배포까지 풀스택 완성

학력

학교	전공	기간
고려사이버대학교	AI·데이터과학부	2022.02 ~ 2026.02 (졸업)
대덕소프트웨어마이스터고등학교	임베디드SW과	2019.03 ~ 2022.02 (졸업)

자격증

- 데이터분석 준전문가 (ADsP) · 한국데이터산업진흥원 · 2024.11
- 정보처리기사 · 한국산업인력공단 · 2019.06
- 컴퓨터활용능력 2급 · 대한상공회의소 · 2017.09
- ITQ 마스터 · 한국생산성본부 · 2017.08

활동

- PillCare — 식의약 공공데이터·AI 분석·활용 경진대회 · 2026