

ML / MLOps.

ML 모델 개발 / MLOps 개발자



여러 모델, 하나의 안정적인 구조

위성영상·드론영상·EO/IR 영상 등 도메인 특성에 맞춰 CNN 계열과 Transformer 계열 모델을 함께 다뤄왔습니다. EO·IR 이중 도메인 UAV 탐지 프로젝트에서는 도메인별 모델 분리 학습으로 주야간 모두 안정적인 탐지 성능을 확보했고, 위험 지역 드론 탐지 프로젝트에서는 **mAP 75%** 수준의 실시간 탐지를 구현했습니다.

모델보다 모델이 도는 환경

사내 MLOps 플랫폼을 구축해 **20개 이상의 모델**을 표준 파이프라인 위에서 운영하며 신규 모델 온보딩을 **1일**로 단축했고, Kubernetes 기반 RTSP 병렬 처리 환경을 설계해 복수 카메라 실시간 스트림을 끊김 없이 처리했습니다.

기술을 업무 효율로 연결

핫딜 등록 자동화로 **4시간 작업을 2분**으로(99%) 단축했고, CS 문의 자동화로 응답 지연을 **80% 줄이며** 24/7 무중단 운영 체계를 만들었습니다.

ABOUT

EMAIL premierckim@gmail.com
GITHUB github.com/my0614
BASE Seoul, Korea
CAREER 5년차


SKILLS

Language · Python, C
NLP/LLM · LLM, RAG, Azure OpenAI, Prompt Engineering
Vision · YOLOv5, Faster R-CNN, RetinaNet, MMDetection, MambaCD
AI Framework · PyTorch, LangChain
Backend · Flask, FastAPI
DB · PostgreSQL, Redis, ChromaDB(Vector DB), BigQuery
Infra · Docker, Kubernetes
Cloud · Azure, AWS EC2
Else · Git, Jira, Label Studio, MLflow


Projects

사내 MLOps 플랫폼 DFLOW

한컴인스페이스 · 2022 ~ 2024



아키텍처



사내 MLOps 플랫폼 DFLOW

개요

AI 모델 개발 과정에서 반복적으로 발생하는 데이터 라벨링, 학습 환경 구축, GPU 자원 관리, 성능 검증, 모델 배포 준비 과정을 표준화하기 위해 통합 MLOps 플랫폼을 구축했습니다. 데이터셋 관리부터 학습 작업 스케줄링, 학습 추적, 성능 평가, ONNX 모델 추출까지 End-to-End 파이프라인을 제공하여 개발 효율성과 모델 품질 관리 체계를 강화했습니다.

9개 20+ 지원 모델 수
4~2주 1일 신규 모델 온보딩
K8s 전 컴포넌트 파드 운영

역할

GOD(General Object Detection)

Redis BRPOP 기반 학습 작업 큐

실시간 학습 모니터링 및 사용자 기능

nvidia-smi 기반 GPU 동적 분배

사용자 입력 기반 config 자동 생성 파이프라인


MMDetection MMYOLO GOD Redis K8s PyTorch Docker PostgreSQL ONNX

GOD(General Object Detection): YOLO · Faster R-CNN · RetinaNet ML 백엔드 직접 구현 — MMDetection · MMYOLO와 동일한 공통 인터페이스로 추상화

배경	GOD · MMDetection · MMYOLO 프레임워크별로 상이한 학습 인터페이스를 단일 공통 구조로 추상화. 신규 모델 추가 시 인터페이스 재구현 없이 config 교체만으로 온보딩
해결	- YOLO · Faster R-CNN · RetinaNet 등 모델별 상이한 인터페이스 → 공통 추상화 레이어 설계 - GOD · MMDetection · MMYOLO 3개 프레임워크를 단일 ML 백엔드 인터페이스로 통합 - 전이학습·초기학습 선택, 학습 파라미터 주입을 공통 API로 표준화 - 신규 모델 온보딩: 코드 수정 없이 config 파일 교체만으로 처리, 1~2주 → 1일 이내 - 지원 모델 수 3개 → 20개 이상으로 확장

Redis BRPOP 기반 학습 작업 큐

배경	DB 폴링 race condition → Redis BRPOP 원자적 연산으로 해결, Redis Hash로 job 상태·GPU·에러 로그 중앙 관리
해결	- BRPOP: 원자적 pop으로 race condition 없는 작업 분배 보장 - Redis Hash: job 상태·GPU 번호·에러 로그 중앙 관리 → 실시간 상태 API - 작업 실패 시 에러 메시지 저장으로 디버깅 가능한 구조 확보



모델 학습 상태 관리 (Connected → Preparing → Training)

MM_cascade
Failed

URL http://192.168.0.75:9096

Version unknown

Model Type cascade_v1.0

☐ 초기학습


Start Training

no data for transfer learning: Please add data to train

학습 작업 에러 로그 확인

실시간 학습 모니터링 및 사용자 기능

배경	학습 진행률·버전·성능 지표를 실시간으로 시각화하고, 자동 라벨링·모델 비교·프로젝트 접근 제어 등 end-to-end 사용자 기능 제공
해결	• 학습 완료 weight로 자동 라벨링 실행 — 수동 라벨링 비용 절감 및 재학습 사이클 단축 • 학습 진행률 실시간 표시 (Connected → Preparing → Training 상태 관리) • 학습 결과 성능 지표(mAP · Loss 등) 그래프 시각화 대시보드 제공 • 원하는 성능 지표 선택 후 모델 간 수치 비교 기능 • 버전 관리: 학습 이력·파라미터·성능 지표를 버전별로 기록·조회 • 프로젝트별 그룹 생성 + 비밀번호 인증 기반 접근 제어로 다중 프로젝트 환경 데이터 격리 지원



학습 완료 weight 기반 자동 라벨링




모델 성능 평가 대시보드

nvidia-smi 기반 GPU 동적 분배

배경	job 처리 전 nvidia-smi로 가용 메모리 체크 → 모델 요구량 비교 후 GPU 할당, 조건 미충족 시 재큐잉으로 OOM 제거
해결	• nvidia-smi --query-gpu로 가용 메모리 실시간 조회 • 모델 config에 min_gpu_memory 정의, Worker가 조건 검증 후 GPU 할당 • 멀티 GPU OOM 장애 제거, 안정적 동시 학습 지원

사용자 입력 기반 config 자동 생성 파이프라인

배경	사용자가 UI에서 입력한 학습 파라미터·모델·데이터셋 정보를 받아 프레임워크별 공통 config 파일을 자동 생성·수정 후 학습 실행까지 연결하는 파이프라인 구현
해결	• 사용자 입력(모델 선택·파라미터·데이터셋·전이학습 여부)을 API로 수신 • 수신 정보 기반으로 MMDetection · MMYOLO · GOD 공통 config 자동 생성·수정 • config 완성 → Redis 큐 등록 → Worker 학습 실행까지 자동 연결 • 학습 완료 후 weights 다운로드 및 ONNX 변환 기능 제공




모델 선택 및 학습 파라미터 입력 UI

- 멀티 GPU OOM 장애 제거, 학습 대기 하루 이상 → Redis 큐 자동 순차 처리로 해소
- 라벨링 결과 COCO·YOLO 포맷 export + 자동 라벨링(Pre-annotation) 연계로 라벨링 사이클 단축
- 학습 완료 weights PyTorch(.pt) · TensorFlow(.pb) · ONNX(.onnx) 3포맷 export 지원
- 데이터 import → 라벨링 → 학습 → 성능 평가 → weights export 전 과정 단일 플랫폼에서 완결

드론 탑재 실시간 객체 탐지

한컴인스페이스 · 2023 ~ 2025



아키텍처



실시간 위협 객체 6종 클래스

개요

전쟁 지역, 붕괴 위험이 있는 터널, 저조도 환경 등 사람이 직접 접근하기 어려운 위험 지역을 안전하게 탐색하기 위해 개발한 드론 기반 객체 탐지 시스템. 드론 영상에서 위험 객체를 실시간으로 탐지하고 3D 좌표로 시각화하여 현장 상황을 원격으로 파악할 수 있도록 지원했습니다.

64%

75%

객체 탐지 mAP

2시간+

1분

네트워크 세팅

KTL

시험 성적서 발급

역할

- 모델 비교 평가 및 Faster R-CNN 선정
- 위험 객체 6종 데이터셋 구축 및 희소 클래스 보완
- 실환경 테스트 기반 반복 성능 개선

Faster R-CNN

ROS

RealSense D435i

Docker

모델 비교 평가 및 Faster R-CNN 선정

배경

Faster R-CNN · YOLOv5 · YOLOv7 · RetinaNet 4종을 Precision·추론 속도·객체 크기 변화 대응력 기준으로 비교 평가. 드론 실시간 영상 추론 환경에서 오탐이 미탐보다 치명적인 프로젝트 특성상 Precision을 최우선 기준으로 삼았고, 촬영 고도·줌 배율에 따라 객체 크기가 크게 달라지는 드론 영상 특성상 크기 변화 대응 안정성까지 종합해 Faster R-CNN을 최종 선정.

해결

- 평가 기준 1 — 오탐률: 위협 오인식은 현장 대응 오류로 직결 → Precision 최우선
- 평가 기준 2 — 추론 속도: 드론 탑재 엠티 환경에서 실시간 처리 가능 여부 검증
- YOLOv5 · YOLOv7 탈락: 속도(~80 / ~59 FPS)는 우수하나 Precision 58~59%로 오탐률이 허용 기준 초과
- RetinaNet 탈락: Precision 96.8%로 수치상 최고였지만, 촬영 고도·줌에 따라 객체 크기가 크게 달라지는 드론 영상에서 작은 객체 탐지가 상대적으로 불안정해 최종 제외
- Faster R-CNN 선정: Precision 95%로 RetinaNet과 근소한 차이(1.8%p)였지만, RPN 기반 2-stage 구조 특성상 크기 변화가 큰 객체에서도 더 안정적으로 탐지해 최종 선정

모델	Precision	FPS	결과
YOLOv5	58%	~80	탈락
YOLOv7	59%	~59	탈락
RetinaNet	96.8%	~17	탈락
Faster R-CNN	95%	~12.5	선정

위협 객체 6종 데이터셋 구축 및 희소 클래스 보완

배경	다양한 환경(조도·각도·거리)에서 위협 객체 6종 약 2,000장 수집·라벨링. 폭발물 등 실사 데이터 확보가 어려운 클래스는 Augmentation 및 목업 데이터셋으로 보완		
해결	- 폭발물 클래스: 실사 데이터 희소 → Augmentation(회전·밝기·노이즈) + 목업 데이터셋 생성으로 클래스 불균형 보완 - 비탐지 클래스 추가 — 오탐 방지를 위해 탐지 대상 외 객체를 background 클래스로 명시적 학습 - Occlusion 대응 — 객체가 절반 이상 가려진 케이스도 탐지되도록 라벨링 기준 수정 - 위협 객체 6종 클래스 정의, 다양한 촬영 환경에서 약 2,000장 수집 및 라벨링		

실환경 테스트 기반 반복 성능 개선

배경	실제 터널 환경 테스트에서 저조도·빛번짐 오염 이슈 발견 → 원인별 데이터 확보 및 재학습으로 대응. 데이터셋 2,000장 → 6,000~7,000장으로 확장
해결	- mAP 61% → 75% (14%p 향상), KTL 시험 성적서 발급 기준 달성 - 이슈 1 — 저조도 환경: 터널 내 조도 저하로 추론 성능 급락 → 고조도/저조도 환경 데이터 추가 확보, 총 6,000~7,000장으로 확장 재학습 - 이슈 2 — 플래시 빛번짐 오염: 빛번짐을 객체로 오인식, 특히 bomb 클래스 Precision 56.5%(FP 127건)로 집중 발생 → 빛번짐 패턴을 배경 이미지로 추가 학습하여 오염률 감소 - 이슈 3 — injured_person 탐지 누락: Recall 60.4%(FN 44건)으로 가장 낮은 검출률 → Occlusion·저조도 환경 데이터 보강으로 대응

SW Version: AutoTAR 1.0.0 Dataset: /data/dataset/flight_drone/KTL_dataset_result/ IOU Threshold: 0.5				
Precision / Recall / mAP@0.5 / Ratio				
Class	Precision	Recall	mAP@0.5	Ratio
bomb	56.51%	76.74%	45.80%	23.27%
exit	72.94%	73.81%	49.40%	9.09%
fire	89.33%	87.85%	43.44%	19.59%
injured_person	87.01%	60.36%	38.54%	12.01%
oil	77.65%	75.86%	53.83%	18.83%
person	78.06%	76.10%	49.98%	17.21%
Mean	76.92%	75.12%	46.83%	100.00%

클래스별 성능 지표 (Precision · Recall · AP@0.5)

클래스	Precision	Recall	AP@0.5
bomb	56.5%	76.7%	70.2%
exit	72.9%	73.8%	73.1%
fire	89.3%	87.9%	86.8%
injured_person	87.0%	60.4%	59.2%
oil	77.7%	75.9%	73.9%
person	78.1%	76.1%	72.2%

- Faster R-CNN 선정 (Precision 95%, ~12.5 FPS) — 4종 모델 비교 평가 후 오염 최소화 기준으로 채택
- 데이터셋 2,000장 → 6,000~7,000장 확장, 저조도·빛번짐·Occlusion 실환경 이슈 3건 원인별 대응
- RGB/Depth 동기화 기반 실시간 3D 좌표 복원 — GCS에서 위험 객체 위치를 3D 포인터로 확인

EO/IR 센트리 카메라 기반 UAV 실시간 탐지·추적 및 모니터링 시스템

개요

EO·IR 이중 도메인 환경에서 소형 UAV를 실시간으로 탐지·추적하기 위해 구축한 모니터링 시스템. 도메인별 모델 분리 학습과 소형 객체 특화 최적화를 통해 주야간 모두에서 안정적인 탐지 성능을 확보하고, Kubernetes 6개 파드 기반 RTSP 병렬 스트리밍으로 복수 카메라 실시간 처리 환경을 구현했습니다.

EO/IR

도메인별 모델 분리

6채널

실시간 병렬 처리

K8s

파드 기반 운영

역할

K8s 6파드 기반 RTSP 병렬 스트림 처리

EO/IR 도메인별 YOLO 모델 분리 학습

소형 UAV 특화 모델 최적화

YOLOv5

Kubernetes

Docker

RTSP

Python

PyTorch

K8s 6파드 기반 RTSP 병렬 스트림 처리

배경	Kubernetes 위에 파드 6개를 배포하여 EO·IR 카메라별 RTSP 스트림을 독립 파드에서 병렬 수신·추론. Docker 이미지로 모델·런타임 환경을 통일하여 파드 간 일관성 확보
해결	- 파드별 RTSP 스트림 독립 수신으로 단일 카메라 장애가 전체 시스템에 미치는 영향 차단 - Docker 이미지로 YOLO 모델·의존성 패키징, 파드 재시작 시 동일 환경 즉시 복원 - Kubernetes 리소스 제한 설정으로 파드 간 GPU·CPU 자원 경합 방지

EO/IR 도메인별 YOLO 모델 분리 학습

배경	EO·IR 이미지를 단일 데이터셋으로 학습 시 IR 환경에서 새·항공기 오탐이 빈번하게 발생하는 문제를 도메인별 데이터셋 분리 및 독립 학습으로 해결
해결	- EO/IR 도메인별 데이터셋 분리 구축, 오탐 케이스 및 다양한 배경 이미지를 추가 학습하여 UAV 고유 패턴 학습 - IR 모델: 새·항공기 등 비객체 오탐 케이스를 background 클래스로 명시적 학습하여 오탐 빈도 감소 - EO 모델: 주간 다양한 조도·각도 환경 데이터 확보로 배경 유사 객체 탐지율 향상


소형 UAV 특화 모델 최적화

배경	원거리 소형 UAV는 표준 앵커 설정과 입력 해상도에서 탐지율이 저하되는 문제를 고해상도 입력·소형 객체 특화 앵커·데이터 증강으로 개선
해결	- 고해상도 입력 적용으로 원거리 소형 객체 특징 보존 및 탐지율 향상 - 소형 객체 특화 앵커 설정 조정으로 작은 바운딩 박스 예측 정확도 개선 - mosaic·확대 crop 등 데이터 증강 기법으로 소형 객체 학습 샘플 다양성 확보


- EO/IR 환경별 최적화로 주야간 모두에서 안정적인 탐지 성능 확보, IR 오탐 발생 빈도 감소
- 소형 UAV 탐지율 향상 및 미탐 케이스 감소, 원거리 소형 객체에 대한 모델 탐지 신뢰도 개선
- 6개 파드 병렬 처리로 복수 카메라 실시간 탐지 환경 구현, 단일 파드 장애 시에도 나머지 채널 정상 운영

핫딜 자동화 시스템

(주)무무즈 · 2025.12 ~ 2026.03



아키텍처



무무즈 핫딜 오픈 화면

개요

단독 최저가 상품을 빠르게 발굴하고 경쟁사보다 먼저 프로모션을 진행하기 위해 구축한 핫딜 운영 자동화 시스템. 파트너사 신청부터 상품 선정, 등록, 결과 메일 발송까지의 업무를 자동화하여 운영 시간을 단축하고, 더 많은 핫딜을 안정적으로 운영할 수 있는 환경을 구축했습니다.

4시간+

2분

등록 작업 시간

99%↓

작업 시간 단축

무인

전 과정 자동화

역할

Shopby API·BigQuery 연계 상품 매칭 및 랭킹 알고리즘

OAuth 2.0

AWS EC2 + cron 실행 환경 및 CI/CD

OAuth 2.0

Google Sheets API

Gmail API

Shopby API

AWS EC2

BigQuery

Bitbucket Pipelines

Cron

Python

Shopby API·BigQuery 연계 상품 매칭 및 랭킹 알고리즘

배경	Shopby API와 BigQuery를 연계해 상품번호·상품명 등 운영 데이터를 검증·매핑하고, 당회차 실제 등록 상품 비율 기반 동적 가중치 스코어링으로 상위 200개 상품을 자동 선별 및 등록하는 End-to-End 자동화 파이프라인 구축
해결	- 고정 기준값 대신 회차별 실제 데이터를 반영한 동적 스코어링으로 상위 200개 자동 선별 - 할인율·가격 경쟁력·재고 수량 3개 지표를 당회차 실제 등록 상품 비율 기반으로 가중치 산정 - Shopby API·BigQuery 연계로 신청 상품의 상품명·상품번호 등 운영 데이터 검증·매핑 - 신청 접수·현황 관리는 Spreadsheet로 운영하고, 상품 데이터 검증·매핑은 BigQuery에 저장된 운영 데이터를 연계해 처리

OAuth 2.0 — Google Spreadsheet · Gmail 통합 자동화

배경	InstalledAppFlow 기반 OAuth 2.0으로 Gmail · Sheets · Drive 3개 API를 단일 토큰으로 인증, Refresh Token 자동 재발급으로 배치 실행 중 인증 단절 없는 무중단 파이프라인 구축
해결	- Gmail · Sheets · Drive 멀티 스코프를 단일 credential로 통합 인증 - Refresh Token 만료 감지 → 자동 재발급 로직으로 새벽 배치 중 인증 단절 방지 - MIMEMultipart 기반 발송 모듈 직접 설계 — HTML 템플릿 치환 · CID 인라인 이미지 · 파일 첨부 단일 클래스로 캡슐화 - BCC 일괄 발송으로 파트너사 간 수신자 정보 노출 차단

AWS EC2 + cron 실행 환경 및 CI/CD



배경	EC2에서 cron 배치 자동 실행, Bitbucket Pipelines로 push → 테스트 → EC2 배포 완전 자동화
해결	- AWS EC2에서 Python 코드 실행, cron으로 새벽 배치 자동 스케줄링 - Bitbucket Pipelines: push → 테스트 → 빌드 → EC2 배포 자동화 - 브랜치별 배포 환경 분리 (dev / prod) - cron 실행 중 오류 발생 시 Slack Incoming Webhook으로 즉시 알림 발송 - 배치 완료 후 정상·실패 건수 요약 메시지 Slack Incoming Webhook으로 자동 발송 → MD·개발팀이 스케줄링 실행 결과 실시간 확인 가능

→ 파트너사 계정별 결과 파일 메일 발송 자동화로 누락·오입력 리스크 제거


→ 별도 메일링 SaaS·인프라 도입 없이 Google Workspace만으로 자동화 파이프라인 구현

CS 문의 자동화

(주)무무즈 · 2025.12 ~ 2026.03




CS 문의 자동화 시스템 개요



CS 문의 자동화 프로세스

개요

반복적인 배송 문의로 인해 상담 인력이 단순 응대에 집중되는 문제를 해결하고자 구축한 CS 자동화 시스템. 주문 정보를 기반으로 문의를 자동 분류·응답하여 고객 응답 시간을 단축하고 상담 인력이 고부가가치 업무에 집중할 수 있도록 지원했습니다.



역할

이중 API 응답 기반 케이스 분기 설계

Shopby / Sellmate API 이중 연동

배치 스케줄러 기반 자동 처리



이중 API 응답 기반 케이스 분기 설계

배경	Shopby(주문) · Sellmate(재고/배송) 두 API 응답을 매칭하여 상품코드·송장번호 유무 조합으로 3가지 케이스를 분기, 케이스별 HTML 템플릿을 자동 선택해 Shopby answer API로 등록
해결	• 상품코드 X / 송장번호 O → 1-2일 내 출고 안내 템플릿 • 상품코드 O / 송장번호 O → 입고예정일 안내 템플릿 (남대문/리오더) • 상품코드 O / 송장번호 X → 기본 배송 안내 템플릿 • 두 조건 모두 없는 케이스는 자동 처리 제외 → 담당자 플래그 분리, 오답 발송 차단 • 입고예정일 데이터 유효성 검증 — 과거 날짜 등록된 케이스 감지 시 기본 배송 안내로 자동 fallback

Shopby / Sellmate API 이중 연동

배경	주문(Shopby) · 배송(Sellmate) 분리 API를 동시 연동. API 인증 정보(systemkey, mallkey, auth token)는 코드에서 분리해 JSON config 파일로 관리
해결	• Shopby API: 문의 목록 조회 → 주문 상세 조회 → 답변 등록 순으로 처리 • Sellmate API: 주문 조회 → 상품 옵션 조회 → 입고예정일 조회 순으로 처리 • 두 API 응답 매칭 → 상품코드·송장번호 조합으로 케이스 판단 후 자동 응답 생성 • API 인증 정보(systemkey, mallkey, auth token)를 코드에서 분리하여 JSON config 파일로 관리

배치 스케줄러 기반 자동 처리

배경	웹훅 대신 주기 배치로 미처리 문의 일괄 조회, 주말·야간 포함 24/7 무중단 자동 처리
해결	• cron 기반 스케줄러로 1시간 주기 배송 문의 일괄 수집 및 자동 응답 처리 • 배송 상태 데이터 주기적 갱신으로 응답 정확도 유지 • 주말·비업무 시간 포함 24/7 무중단 운영

→ CS 담당자가 단순 반복 문의에서 벗어나 클레임·환불 등 고부가가치 업무에 집중할 수 있는 운영 환경 구축

→ Shopby·Sellmate 등 이중 API를 단일 인터페이스로 통합하여 신규 판매 채널 연동 및 확장 용이성 확보

→ 자동화된 응답 로직을 통해 상담원 간 응답 편차를 줄이고 일관된 고객 응대 품질 제공

이약머약 — AI 알약 식별 서비스

MS AI School 10기 | Team 4 U · 2026.05.08 ~ 2026.05.20



이약머약 — 사진 한 장으로 알아내는 안전한 복약 가이드

개요

사진 한 장으로 알약을 식별해 약물 정보·DUR 상호작용·도핑 금지 여부까지 즉시 제공하는 Azure Custom Vision 기반 서비스. 약 이름이나 전문 용어를 몰라도 사용할 수 있도록 설계해 고령자·정보 취약 계층의 복약 안전성을 높였습니다.



역할

Azure Custom Vision 알약 90종 분류 모델

실사용 환경 대응

Azure SDK 기반 FastAPI 비동기 예측 연동

- Python
- FastAPI
- PostgreSQL
- Azure Custom Vision
- Azure SDK
- Azure VM
- Nginx

Azure Custom Vision 알약 90종 분류 모델

배경	색상·모양·각인을 종합 분석하는 엔터프라이즈급 이미지 분류 모델 구축, 처방 통계·판매량 기반으로 핵심 90종 선별
해결	- 처방 통계·판매량 기반으로 핵심 90종만 선별 수집해 클라우드 비용 절감 및 모델 실용성 향상 - 학습 데이터 3,773개로 90종 분류 모델 학습, 성능지표 평균 97% 달성

실사용 환경 대응 — 배경 제거·증강 전략 재설계

배경	공공 데이터만으로 학습할 때 발생하는 도메인 갭을 배경 제거 전처리와 Background Augmentation으로 해소
해결	- 배경 제거 전처리 + Background Augmentation으로 탁자·손바닥 등 실사용 환경 재학습 - 회전 범위 -45°~45° → -10°~10° 축소, 복합 증강(원근·노이즈·가림) 제거로 각인·형태 보존


Azure SDK 기반 FastAPI 비동기 예측 연동

배경	Azure Python SDK로 Custom Vision 예측 API를 FastAPI 비동기 엔드포인트에 통합해 평균 응답 2.4초 확보
해결	- Azure Python SDK Custom Vision 예측 API를 FastAPI 비동기 엔드포인트와 통합 - AI 분석 평균 2.4초, 전체 응답 3초 이내로 사용자 체감 대기 시간 최소화

- Azure Custom Vision 모델 성능지표 평균 97% 달성 — 학습 데이터 3,773개, 분류 클래스 90종
- Azure SDK 기반 예측 API 연동으로 AI 분석 평균 2.4초, 전체 응답 3초 이내 확보
- 약 이름을 몰라도 사진 한 장으로 DUR·도핑·병용금기까지 제공하는 고령자 친화 서비스를 2주 내 기획→학습→배포까지 완성

PillCare

Team Project · 2026.05



PillCare 서비스 화면

개요

사용자의 복약 이력, 건강 지표, 생활 환경 데이터를 통합 분석하여 잠재적인 건강 위험을 조기에 예측하기 위해 개발한 서비스. 멀티모달 데이터를 기반으로 개인 맞춤형 건강 인사이트를 제공하고 예방 중심의 건강 관리를 지원했습니다.

45 테이블

11

도메인 설계

3단계

멀티 레이어 캐시

MCP

AI Agent 연동

FastMCP 기반 건강 데이터 MCP 서버

3단계 멀티 레이어 캐시 (메모리 → Redis → OpenAI)

OpenAI Vision API 처방봉투 OCR

- FastAPI
- FastMCP
- OpenAI SDK
- Redis
- OAuth 2.0
- Pydantic
- WeasyPrint
- pytest

FastMCP 기반 건강 데이터 MCP 서버

배경	건강 데이터 분석 로직을 MCP Tool로 표준화, AI 어시스턴트가 실시간 건강 데이터 직접 조회 · 개인화 응답 생성
해결	- FastMCP로 MCP 서버 구현, 건강 지수·약물 안전도·환경 지수 3개 Tool 등록 - AI 어시스턴트가 실시간 사용자 건강 데이터를 직접 조회해 개인화 응답 생성

3단계 멀티 레이어 캐시 (메모리 → Redis → OpenAI)


배경	LLM 비용·속도·장애 격리를 위한 3단계 캐시 설계, L2 히트 시 L1 자동 워밍업 · Redis 장애 시 OpenAI 폴백으로 무중단 보장
해결	- L1 인메모리(6h TTL) → L2 Redis(자정 초기화) → L3 OpenAI 순으로 캐시 히트 처리 - L2 히트 시 L1 자동 워밍업으로 후속 요청 응답 속도 향상

OpenAI Vision API 처방봉투 OCR

배경	처방봉투 이미지 → OpenAI Vision API 파싱 → 약품명·용량·복용 시점 추출, 복약 스케줄 자동 등록
해결	- 처방봉투 이미지 업로드 → OCR 파싱 → 약품명·용량·복용 시점 자동 추출 - 파싱 결과를 복약 스케줄에 즉시 자동 등록, 수동 입력 단계 제거

뿌라인드

Team Project · 2026.06 ~ 2026.07



홈 대시보드 — 관계 상태를 한 화면에서 확인

개요

부부·연인의 말하지 못한 속마음과 반복되는 갈등 패턴을 기록하면 AI가 감정을 분석하고, 거친 말투를 부드럽게 변환하고, 관계 회복 액션을 제안하는 관계 케어 웹앱. 5인 팀에서 DB·AI 분석 파이프라인을 담당해 LangChain 기반 RAG 상담 챗봇, pgvector 벡터 유사도 검색, LLM 구조화 분석까지 실제 운영을 가정한 데이터 설계를 맡았습니다.

RAG

LangChain 기반 법령·판례 상담 챗봇

pgvector

임베딩 유사도 검색 — 추천·중복판별

14개 그룹

81개


LLM 구조화 분석 라벨

역할

RAG 오케스트레이션 레이어

pgvector 벡터 검색과 문자열 유사도 판별

LLM 감성 분석 파이프라인



RAG 오케스트레이션 레이어 — Azure AI Search 위의 검색·실패 정책 설계

배경	Azure AI Search 관리형 RAG 인프라 위에서, 검색 트리거 조건·scope 엄격도·폴백 전략을 응답 유형별로 설계하는 애플리케이션 레벨 오케스트레이션 레이어를 구축. 자유 대화형 상담(뽀냥 챗봇)에는 키워드 기반 조건부 검색 트리거와 in_scope=False를 적용해 근거 문서가 부족해도 상담 흐름이 끊기지 않도록 하고, 법률·제도 질문에는 상시 검색과 in_scope=True를 적용해 근거 없는 응답 생성을 차단
해결	- 임베딩·청킹·인덱싱은 Azure AI Search(On Your Data) 관리형 기능에 위임하고, 언제 검색을 트리거할지·얼마나 엄격하게 근거를 요구할지·실패 시 어떻게 대응할지의 애플리케이션 정책 설계에 집중 - 가사소송법·양육비 관련 법령과 최근 20년 이혼 재산분할·양육비 대법원 판례를 대상으로 LangChain 리트리버·프롬프트·LLM 체인을 구성해 출처를 명시한 상담 응답을 생성

pgvector 벡터 검색과 문자열 유사도 판별 — 유사 고민 추천 · 중복 저장 판별

배경	PostgreSQL에 pgvector 확장을 적용해 별도 벡터 DB 인프라 없이 커뮤니티 유사 고민 추천을 임베딩 유사도 검색으로 처리하고, 감정 기록 중복 판별은 같은 DB 안에서 문자열 유사도(difflib.SequenceMatcher) 비교로 가볍게 처리하는 구조를 설계
해결	- 커뮤니티 게시글을 임베딩으로 변환해 pgvector 코사인 유사도로 나와 가장 비슷한 상황의 공감 글을 우선 노출 - 키워드 매칭의 한계(표현은 달라도 감정·상황 맥락이 유사한 글을 못 찾는 문제)를 임베딩 유사도 검색으로 해결

LLM 감정 분석 파이프라인 — 14그룹 81라벨 JSON Schema 구조화

배경	Azure OpenAI가 감정·갈등 원인·반복 패턴·숨은 욕구를 자유 문장이 아닌 14개 그룹 · 81개 라벨의 JSON Schema 강제 포맷으로 구조화 추출하도록 프롬프트와 스키마를 설계
해결	- Gottman 4대 파괴 대화 패턴(비난·방어·경멸·담쌓기) + PHQ-9 척도를 라벨 판단 기준으로 결합해 도메인 전문성 반영 - emotion·cause·pattern·risk 등 필수 필드와 enum 값을 JSON Schema로 강제해 LLM 응답의 필드 누락·중복·포맷 깨짐을 방지하고 DB에 안정적으로 저장

→ 22개 핵심 화면·기능, LangChain·pgvector·Azure OpenAI를 엮은 81라벨 AI 분석 파이프라인을 기획 → 구현 → Azure 연동 → 교차 검증까지 완주

→ 전체 예산 약 60만 원 중 약 10만 원(16.7%) 사용 — MVP 검증 비용을 예산 내에서 안정적으로 관리